Elección Discreta: Teoría, estimación y métodos númericos

Tarea 1*

Germán Augusto Campos Ortíz** Juan José Merino Zarco***

07 de febrero de 2022

1. Problema 1 - Logit condicional

1.1. Inciso 1)

Implementa el modelo logit condicional usando los datos en yogurt.csv.

El modelo se implementó utilizando el lenguaje de programación *Python*. El código se envía de forma adjunta mediante un archivo tipo Notebook (.ipynb) y a su vez, en el anexo de este documento se presentará el código con todos los outputs obtenidos.

1.2. Inciso 2)

Reporta los coeficientes estimados y el error estándar

En el cuadro 1 se presentan las estimaciones y los errores estándar de los coeficientes del modelo. Cabe anotar que para la estimación el valor del coeficiente **alpha4** se normalizo haciéndolo igual a cero, por lo cual no se reportará su coeficiente y su error estimado.

Cuadro 1: Coeficientes estimados y errores estándar

Coeficiente	Valor estimado	Error estándar
Alpha_1	1.3879	0.03242
Alpha_2	0.6434	0.06115
Alpha_3	-3.0861	0.10753
Beta_price	-37.0643	0.91880
Beta_feat	0.4872	0.12268

1.3. Inciso 3)

Reporta el valor de la máxima verosimilitud, el índice de verosimilitud y AIC

*El Colegio de México 2020-2022. Profesor: Edwin Muñoz Rodríguez

**El Colegio de México, gacampos@colmex.mx

***El Colegio de México, jmerino@colmex.mx

En el cuadro 2 se reporta el valor de la máxima verosimilitud del modelo, así como el índice de razón de verosimilitud junto al criterio de información de Akaike (AIC) del modelo.

Cuadro 2: Indicadores del modelo estimado

Indicador	Valor
Valor máxima verosimilitud	-2658.5567
Índice de razón de verosimilitud	0.2108
Criterio de información de Akaike (AIC)	5327.1134

1.4. Inciso 4)

Calcula las elasticidades precio propias y cruzadas, e interpreta los resultados

En el cuadro 3 se presentan las elasticidades precio propias de cada producto.

Cuadro 3: Elasticidades precio propias

Elasticidades propias	Valor
Bien 1	-2.7018
Bien 2	-1.8449
Bien 3	-1.9335
Bien 4	-2.2883

Encontramos que un incremento en el 1 % del precio del bien 1, reduce la probabilidad de consumir el bien 1 en un 2.70 %. A su vez, incrementos en el 1 % del precio del bien 2 reduce la probabilidad de consumir el bien 2 en un 1.84 %. Así mismo, se evidencia que incrementos en el 1 % en los precios de los bienes 3 y 4 reducen la probabilidad de consumir esos bienes en un -1.93 % y -2.28 % respectivamente. Por lo cual, la probabilidad de consumir los bienes 1 y 4 son los más sensibles con respecto a los cambios en sus precios.

Por su parte, en el cuadro 4 se pueden observar las elasticidades precio cruzadas con respecto al cambio en los precios. En la primera fila se encuentra la elasticidad de la probabilidad de consumo de cualquier bien ante cambios en precio del bien 1, mientras que en la fila 2 se encuentra la elasticidad de la probabilidad de consumo de cualquier bien con respecto a un cambio en el precio del bien 2; y así sucesivamente para las elasticidades de la fila 3 y 4.

Cuadro 4: Elasticidades precio cruzadas

Elasticidades cruzadas	Valor
Con respecto a cambio en precio del bien 1	1.2365
Con respecto a cambio en precio del bien 2	1.1772
Con respecto a cambio en precio del bien 3	0.05412
Con respecto a cambio en precio del bien 4	0.6588

Encontramos que un incremento del 1 % del precio del bien 1, aumenta la probabilidad de consumir las otras 3 alternativas (bien 2, 3 y 4) en un 1.23 %. A su vez, incrementos en 1 % del precio del bien 2, aumenta las probabilidades de consumir los otros bienes en un 1.17 %. En relación a los posibles aumentos del 1 % en los precios del bien 3 y 4, esto aumenta la probabilidad de consumir los otros bienes en un 0.05 % y en un 0.65 %, respectivamente.

2. Problema 2 - Fake data

2.1. Inciso 1)

Reporta la mediana de los estimadores para cada uno de los 5 coeficientes.

Cuadro 5: Mediana de los coeficientes estimados

Coeficiente	Mediana
Alpha_1	0.940027
Alpha_2	-0.909311
Alpha_3	0.554207
Alpha_4	0
Beta_price	-19.57092
Beta_feat	1.912652

2.2. Inciso 2)

Reporta un histograma con la distribución de los estimadores para cada coeficiente

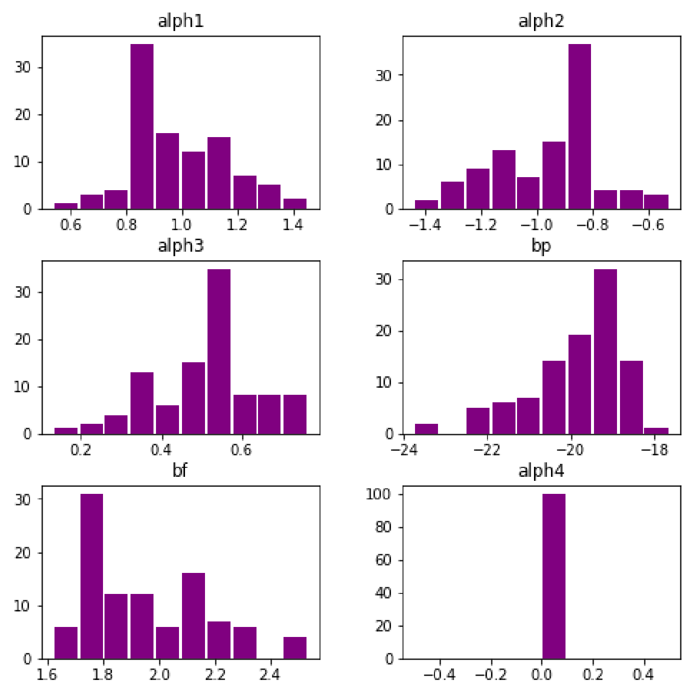

Figura 1: Histograma del valor estimado de los coeficientes

2.3. Inciso 3)

Comentarios sobre la calidad de la rutina de estimación

Dados los coeficientes $\alpha_1 = 1, \alpha_2 = -1, \alpha_3 = 0{,}5, \alpha_4 = 0, \beta_p = -20, \beta_p = 2$, al compararlo con los valores observados, podemos fácilmente que presentan los mismos signos. Las diferencias entre el coeficiente dato y el obtenido derivado de la simulación, son inferiores al |0,1|. Por lo cual, podemos asegurar que la calidad de nuestro modelo de estimación es confiable.

Además, el proceso que se utilizó fueron Estimaciones de rutina, para estimar la desviación estándar de una estadística. Viendo la desviación estándar de los coeficientes:

Cuadro 6: Desviación estándar de los coeficientes estimados

Coeficiente	**Desviación estándar**
Alpha_1	0.181061
Alpha_2	0.182654
Alpha_3	0.129423
Alpha_4	0
Beta_price	1.21693
Beta_feat	0.214169

Al compararlo con los coeficientes podemos notar que se realizó una adecuada rutina de estimación.

Por último, alph4 es igual a 0 en ambos casos ya que fue la opción que se normalizó a cero en la estimación.

Tarea 1, Elección Discreta

Alumnos: Campos Ortíz Germán Augusto, Merino Zarco Juan José

Pregunta 1 Logit condicional (50 puntos)

In [146]:
```
# Importar las librerias necesarias
import pandas as pd
import numpy as np
from scipy import optimize
from sympy import symbols, Matrix, Transpose
from math import e, log, exp
from scipy.optimize import minimize
import math
import numdifftools as nd
import os
```

In [ ]:
```
os.chdir("D:/Usuario/Desktop/Cuarto Semestre/Elección discreta/Tarea 1") #Definir carpeta de trabajo
```

In [147]:
```
# Importar la base de datos
yogurth = pd.read_csv("D:/Usuario/Desktop/Cuarto Semestre/Elección discreta/Tarea 1/yogurt.csv")
```

In [148]:
```
yogurth.head() #Analizamos las variables de la base de datos
```

Out[148]:

	pan.id	expend	income	hhsize	quantity	brand1	brand2	brand3	brand4	feat1	feat2	feat3	feat4	price1	price2	price3	price4
0	1	40.900002	9	2	2	0	0	0	1	0	0	0	0	0.108	0.081	0.061	0.079
1	1	16.809999	9	2	2	0	1	0	0	0	0	0	0	0.108	0.098	0.064	0.075
2	1	4.060000	9	2	2	0	1	0	0	0	0	0	0	0.108	0.098	0.061	0.086
3	1	34.459999	9	2	2	0	1	0	0	0	0	0	0	0.108	0.098	0.061	0.086
4	1	8.390000	9	2	2	0	1	0	0	0	0	0	0	0.125	0.098	0.049	0.079

In [149]:
```
def modelo_yogurth(x):
    """Logit condicional usando los datos en yogurt.csv."""
    alph1,alph2,alph3,bp,bf = x
    # Valores vacios
    num = 0
    lden = 0
    calc = 0
    alph4 = 0
    alphas=[alph1, alph2, alph3, alph4]

    for index, row in yogurth.iterrows():
        #Numerador (realizamos las operaciones correspondientes para el númerador de la ecuación a maximizar)
        for producto in range(4):
            num = num + row[5+producto]* (alphas[producto]+ bp*row[13+producto] + bf*row[9+producto])


        #Denominador (realizamos las operaciones correspondientes para el denominador de la ecuación a maximizar
        den = 0
        for producto in range(4):
            den = den + e**(alphas[producto]+ bp*row[13+producto] + bf*row[9+producto])

        # Aplicamos el resto de la función, junto a la sumatoria faltante
        for producto in range(4):
            lden = lden + row[5+producto]* log(den)

    #Realizamos el cálculo de la función que nos dará la ecuación completa y al final se multiplica por -1 para
    calc = calc + (num-lden)
    return (calc*-1)
```

Corremos varios modelos para robustez

In [201]:
```
#Corremos el modelo con el método de optimización BFGS
x0 = [1,1,1,1,1]
optimize.minimize(modelo_yogurth, x0, method = "BFGS")
```

Out[201]:
```
      fun: 2658.5567041774857
 hess_inv: array([[ 1.05164204e-03, -6.08229964e-05, -1.01467086e-03,
         2.90953841e-03, -7.27087112e-05],
       [-6.08229964e-05,  3.73977543e-03,  1.97541753e-03,
         5.41563773e-02,  3.15377610e-03],
       [-1.01467086e-03,  1.97541753e-03,  1.15643224e-02,
         3.91743576e-02,  2.96343904e-03],
       [ 2.90953841e-03,  5.41563773e-02,  3.91743576e-02,
         8.44203900e-01,  6.51267223e-02],
       [-7.27087112e-05,  3.15377610e-03,  2.96343904e-03,
         6.51267223e-02,  1.50519226e-02]])
      jac: array([ 0.03225708, -0.02999878,  0.01229858,  0.00531006, -0.00912476])
  message: 'Desired error not necessarily achieved due to precision loss.'
     nfev: 548
      nit: 17
     njev: 88
   status: 2
  success: False
        x: array([  1.38799835,   0.64349903,  -3.08611543, -37.06430818,
         0.48720204])
```

In [197]:
```python
#Corremos el modelo con el método de optimización Nelder Mead
x0 = [1,1,1,1,1]
optimize.minimize(modelo_yogurth, x0, method = "Nelder-Mead")
```

Out[197]:
```
 final_simplex: (array([[  1.38775366,   0.64350447,  -3.08611826, -37.05796121,
          0.48741018],
       [  1.387753  ,   0.64350375,  -3.08611516, -37.05789162,
          0.48741456],
       [  1.38775643,   0.64350576,  -3.08611752, -37.05801966,
          0.48741336],
       [  1.38775658,   0.64350536,  -3.08611639, -37.05800015,
          0.48741039],
       [  1.3877559 ,   0.64350585,  -3.08611892, -37.05795726,
          0.48741329],
       [  1.38775498,   0.6435039 ,  -3.08612291, -37.05804902,
          0.48741465]]), array([2658.55669751, 2658.55669751, 2658.55669751, 2658.55669751,
       2658.55669751, 2658.55669751]))
           fun: 2658.5566975057964
       message: 'Optimization terminated successfully.'
          nfev: 544
           nit: 340
        status: 0
       success: True
             x: array([  1.38775366,   0.64350447,  -3.08611826, -37.05796121,
         0.48741018])
```

In [198]:
```python
#Corremos el modelo con el método de optimización L-BFGS-B
x0 = [1,1,1,1,1]
optimize.minimize(modelo_yogurth, x0, method = "L-BFGS-B")
```

Out[198]:
```
      fun: 2658.5567395838625
 hess_inv: <5x5 LbfgsInvHessProduct with dtype=float64>
      jac: array([-0.00982254,  0.00645741, -0.00140972,  0.01550688, -0.00623004])
  message: 'CONVERGENCE: REL_REDUCTION_OF_F_<=_FACTR*EPSMCH'
     nfev: 246
      nit: 26
     njev: 41
   status: 0
  success: True
        x: array([  1.38709327,   0.64342412,  -3.08555182, -37.03610981,
         0.48754416])
```

Modelo final (método BFGS)

In [173]:
```
x0 = [1,1,1,1,1]  #Establecemos el punto inicial para la optimización
modelo = optimize.minimize(modelo_yogurth, x0, method = "BFGS")  #Terminación exitosa
```

In [175]:
```
# Obtenemos los coeficientes estimados
betas_hat = modelo["x"]
betas_hat
```

Out[175]:
```
array([  1.38799835,   0.64349903,  -3.08611543, -37.06430818,
         0.48720204])
```

In [176]:
```
# Errores estándar
# Iniciamos un proceso de varios pasos en código para obtener los errores estándar de los estimadores
hessiano_inv = modelo["hess_inv"]  #Obtenemos la inversa del Hessiano evaluado en el óptimo. Esto es dado por la
hessiano_inv
```

Out[176]:
```
array([[ 1.05164204e-03, -6.08229964e-05, -1.01467086e-03,
         2.90953841e-03, -7.27087112e-05],
       [-6.08229964e-05,  3.73977543e-03,  1.97541753e-03,
         5.41563773e-02,  3.15377610e-03],
       [-1.01467086e-03,  1.97541753e-03,  1.15643224e-02,
         3.91743576e-02,  2.96343904e-03],
       [ 2.90953841e-03,  5.41563773e-02,  3.91743576e-02,
         8.44203900e-01,  6.51267223e-02],
       [-7.27087112e-05,  3.15377610e-03,  2.96343904e-03,
         6.51267223e-02,  1.50519226e-02]])
```

In [177]:
```
hessiano = np.linalg.inv(hessiano_inv)  #Sacamos la inversa del hessiano inverso para tener el hessiano original
hessiano
```

Out[177]:
```
array([[ 697629.37221544, 1826101.31089503,  184279.95423627,
        -144167.80033842,  208257.97719531],
       [1826101.31089501, 4787620.51721891,  482794.55368633,
        -377942.09821352,  545916.18547406],
       [ 184279.95423626,  482794.55368633,   48804.27082623,
         -38118.83378169,   55056.02688032],
       [-144167.80033842, -377942.09821352,  -38118.83378169,
          29837.47313902,  -43103.56249922],
       [ 208257.97719531,  545916.18547407,   55056.02688032,
         -43103.56249922,   62349.73051413]])
```

In [178]:
```
I =  np.dot((-1/2430), hessiano) #Hacemos operaciones para obtener el valor I y posteriormente la matriz de vari
I
```

Out[178]:
```
array([[ -287.09027663,  -751.48202094,   -75.83537211,    59.3283129 ,
          -85.70287127],
       [ -751.48202094, -1970.21420462,  -198.68088629,   155.53172766,
         -224.65686645],
       [  -75.83537211,  -198.68088629,   -20.08406207,    15.68676287,
          -22.65680119],
       [   59.3283129 ,   155.53172766,    15.68676287,   -12.27879553,
           17.73809156],
       [  -85.70287127,  -224.65686645,   -22.65680119,    17.73809156,
          -25.65832531]])
```

In [179]:
```
mat_var_cov = np.linalg.inv(I)  #Aplicamos la matriz inversa a I y así obtenemos la matriz de varianzas y covari
mat_var_cov = np.dot(-1,mat_var_cov)  #Multiplicamos por -1 dado que la función original la habíamos multiplicad
mat_var_cov
```

Out[179]:
```
array([[ 2.55549016e+00, -1.47799881e-01, -2.46565020e+00,
         7.07017835e+00, -1.76682168e-01],
       [-1.47799881e-01,  9.08765430e+00,  4.80026459e+00,
         1.31599997e+02,  7.66367592e+00],
       [-2.46565020e+00,  4.80026459e+00,  2.81013034e+01,
         9.51936889e+01,  7.20115687e+00],
       [ 7.07017834e+00,  1.31599997e+02,  9.51936889e+01,
         2.05141548e+03,  1.58257935e+02],
       [-1.76682168e-01,  7.66367592e+00,  7.20115687e+00,
         1.58257935e+02,  3.65761718e+01]])
```

In [180]:
```
np.shape(mat_var_cov)
```

Out[180]:
```
(5, 5)
```

In [181]:
```
# Errores estándar en orden (alpha1, alpha2, alpha3, beta_price, beta_feat)
for i in range(5):
    e_e = (math.sqrt(mat_var_cov[i,i]))  / (math.sqrt(2430))
    print(e_e)
```

```
0.03242903082124185
0.06115370333979283
0.1075375394208378
0.9188056923352057
0.12268627701363234
```

In [183]:
```
# Valor de la máxima verosimilitud
mv_betas = - modelo_yogurth(modelo["x"])
mv_betas
```

Out[183]:
```
-2658.5567041774857
```

In [184]:
```
# Valor para las coeficientes en cero
mv_ceros = - modelo_yogurth((0,0,0,0,0))
mv_ceros
```

Out[184]:
```
-3368.6952975211507
```

In [185]:
```
# Índice de razón de verosimilitud
razon_vero = 1 - (mv_betas / mv_ceros)
razon_vero
```

Out[185]:
```
0.2108052318849435
```

In [186]:
```
# Criterior de información de Akaike (AIC)
aic = (-2 * mv_betas) + (2*5)     #5 parametros
aic
```

Out[186]:
```
5327.113408354971
```

In [7]:
```python
# Elasticidades
yogurth.head()
```

Out[7]:

	pan.id	expend	income	hhsize	quantity	brand1	brand2	brand3	brand4	feat1	feat2	feat3	feat4	price1	price2	price3	price4
0	1	40.900002	9	2	2	0	0	0	1	0	0	0	0	0.108	0.081	0.061	0.079
1	1	16.809999	9	2	2	0	1	0	0	0	0	0	0	0.108	0.098	0.064	0.075
2	1	4.060000	9	2	2	0	1	0	0	0	0	0	0	0.108	0.098	0.061	0.086
3	1	34.459999	9	2	2	0	1	0	0	0	0	0	0	0.108	0.098	0.061	0.086
4	1	8.390000	9	2	2	0	1	0	0	0	0	0	0	0.125	0.098	0.049	0.079

In [187]:
```
def probabilidad_eles(dataframe):
    """Logit condicional usando los datos en yogurt.csv."""
    # Importar la base de datos
    moi = pd.read_csv(dataframe)
    #Parametros
    # alph1,alph2,alph3,bp,bf = x
    #Evaluando los parametros en el optimo
    alph1 = 1.38796
    alph2 = 0.643527
    alph3 = -3.086088
    alph4 = 0
    bp    = -37.0679
    bf    = 0.4876
    # Valores vacios
    num = 0
    lden = 0
    calc = 0
    conca1, conca2, conca3, conca4= [],[],[],[]
    alphas=[alph1, alph2, alph3, alph4]
    for index, row in moi.iterrows():

        #Denominador
        den = 0
        for producto in range(4):
            den += exp(alphas[producto]+ bp*row[13+producto] + bf*row[9+producto])

        # Probabilidad
        proby1 = 0
        proby2 = 0
        proby3 = 0
        proby4 = 0
        for producto in range(4):

            num = exp(alphas[producto]+ bp*row[13+producto] + bf*row[9+producto])  #Numerador de la ecuación

            if producto == 0:         #Creamos 4 columnas (variables) a partir de una condición para cada probab
                proby1 += (num)/den

            elif producto == 1:
                proby2 += (num)/den

            elif producto == 2:
```

```
                proby3 += (num)/den

            else:
                proby4 += (num)/den


        conca1.append(proby1)   #Con este codigo logramos generar las columnas finales de cada probabilidad de c
        conca2.append(proby2)
        conca3.append(proby3)
        conca4.append(proby4)

    base = pd.concat([moi,pd.DataFrame(conca1)],axis=1)   #Unimos cada columna en un solo dataframe
    base.rename({0: 'proba1'}, axis=1, inplace=True)
    base = pd.concat([base,pd.DataFrame(conca2)],axis=1)
    base.rename({0: 'proba2'}, axis=1, inplace=True)
    base = pd.concat([base,pd.DataFrame(conca3)],axis=1)
    base.rename({0: 'proba3'}, axis=1, inplace=True)
    base = pd.concat([base,pd.DataFrame(conca4)],axis=1)
    base.rename({0: 'proba4'}, axis=1, inplace=True)


    #Calculo
    return base #La función devuelve la base final con las 4 columnas de probabilidad
```

In [190]:
```
elas = probabilidad_eles("yogurt.csv")  #Generamos un dataframe uniendo a yogurth con las columnas de probabilia
```

In [191]:
```
elas.insert(22, "Bz", -37.0679, allow_duplicates=False)   #Creamos una columna con el valor estimado de beta_pri
```

In [192]:
```
##Los valores de la probabilidad, los precios y la beta_price los cambiamos a formato float
elas["proba1"] = elas["proba1"].astype(float, errors = 'raise')
elas["proba2"] = elas["proba2"].astype(float, errors = 'raise')
elas["proba3"] = elas["proba3"].astype(float, errors = 'raise')
elas["proba4"] = elas["proba4"].astype(float, errors = 'raise')
elas["Bz"] = elas["Bz"].astype(float, errors = 'raise')
elas["price1"] = elas["price1"].astype(float, errors = 'raise')
elas["price2"] = elas["price2"].astype(float, errors = 'raise')
elas["price3"] = elas["price3"].astype(float, errors = 'raise')
elas["price4"] = elas["price4"].astype(float, errors = 'raise')
```

In [193]:
```
# Elasticidades propias
# Procedemos a calcular las elasticidades propias creando 4 columnas por cada elasticidad para todas las filas
elas["elas_prop1"] = elas["Bz"] * elas["price1"] * (1-elas["proba1"])
elas["elas_prop2"] = elas["Bz"] * elas["price2"] * (1-elas["proba2"])
elas["elas_prop3"] = elas["Bz"] * elas["price3"] * (1-elas["proba3"])
elas["elas_prop4"] = elas["Bz"] * elas["price4"] * (1-elas["proba4"])
```

In [194]:
```
# Elasticidades propias
# Procedemos a calcular la media de cada elasticidad (columnas creadas anteriormente) y así tener la elasticidad
mean_elas_prop1 = elas["elas_prop1"].mean()
mean_elas_prop2 = elas["elas_prop2"].mean()
mean_elas_prop3 = elas["elas_prop3"].mean()
mean_elas_prop4 = elas["elas_prop4"].mean()
print(mean_elas_prop1, mean_elas_prop2,mean_elas_prop3,mean_elas_prop4)
```

```
-2.7018539273468907 -1.8449276745364236 -1.9335257784215978 -2.2883520840465748
```

In [195]:
```
# Elasticidades cruzadas
# Procedemos a calcular las elasticidades cruzadas creando 4 columnas por cada elasticidad para todas las filas
elas["elas_cru21"] = elas["Bz"] * elas["price1"] * (-elas["proba1"])
elas["elas_cru12"] = elas["Bz"] * elas["price2"] * (-elas["proba2"])
elas["elas_cru13"] = elas["Bz"] * elas["price3"] * (-elas["proba3"])
elas["elas_cru14"] = elas["Bz"] * elas["price4"] * (-elas["proba4"])
```

In [196]:
```
# Elasticidades cruzadas
# Procedemos a calcular la media de cada elasticidad (columnas creadas anteriormente) y así tener la elasticidad
mean_elas_cru1 = elas["elas_cru21"].mean()
mean_elas_cru2 = elas["elas_cru12"].mean()
mean_elas_cru3 = elas["elas_cru13"].mean()
mean_elas_cru4 = elas["elas_cru14"].mean()
print(mean_elas_cru1, mean_elas_cru2,mean_elas_cru3,mean_elas_cru4)
```

```
1.2365265439885769 1.1772807967618553 0.05412215776737161 0.6588206521043347
```

Pregunta 2: Fake data (50 puntos)

In [202]:
```python
import pandas as pd
import numpy as np
import random
from scipy import optimize, stats
from math import e, log,exp
import math as mt
import matplotlib.pyplot as plt
from scipy.stats import bernoulli
```

1. Generación de 100 bases de datos con 5000 observaciones cada una

Se generaran datos pseudo-aleatorios , empleando una distribución de Bernoulli para construir la característica "feat", una distribución log-normal para los precios de los 4 productos para las N observaciones.

In [209]:

```
"""Creación de las bases de datos"""
# Parametros de la función
## N = Número de datos, ##J= Número de bases
N=5000
J=100
# Precios promedio
yogurt = pd.read_csv("yogurt.csv")
precios = yogurt[['price1', 'price2', 'price3', 'price4']]
precios_promedio = list(precios.mean())

# Valores de los parámetros
beta_p_s=np.array([1,-1,0.5,0,-20,2])

#  Valores vacios
base_precios = pd.DataFrame(np.nan, index = range(N), columns = ['price1', 'price2', 'price3', 'price4'])
atributos = pd.DataFrame(np.nan, index = range(N), columns = ['feat1', 'feat2', 'feat3', 'feat4'])
dict_data_frames = {}

# Creación de las bases
bases = [str("base") + str(x) for x in range(J)]

# Generar las características en cada base
for base in bases:
    for j in range(4):
        base_precios.iloc[:,j] = np.random.lognormal(precios_promedio[j],0.6,N)
        atributos.iloc[:,j] = bernoulli.rvs(size = N,p = 0.5)
        df = pd.concat([base_precios,atributos], axis=1)

    dict_data_frames[base] = df


# Loop para simular la elección de los consumidores
for base in bases:

    ele1,ele2,ele3,ele4 = [],[],[],[]

    for index, row in dict_data_frames[base].iterrows():
        s_1 = np.array([1,0,0,0,row[0],row[4]])
        s_2 = np.array([0,1,0,0,row[1],row[5]])
        s_3 = np.array([0,0,1,0,row[2],row[6]])
        s_4 = np.array([0,0,0,1,row[3],row[7]])
```

```
        for i in [1,2,3,4]:
            globals()['exp_%s' %i] = mt.exp(np.dot(globals()['s_%s' %i],beta_p_s))    #iterar por nombres

        total_exp = exp_1+exp_2+exp_3+exp_4

        for j in [1,2,3,4]:
            globals()['prob_%s' %j] = (globals()['exp_%s' %j]) / (total_exp)

        eleccion=np.random.choice((1,2,3,4),p=[prob_1,prob_2,prob_3,prob_4])

        if eleccion==1:
            ele1.append(1)
            ele2.append(0)
            ele3.append(0)
            ele4.append(0)

        elif eleccion==2:
            ele1.append(0)
            ele2.append(1)
            ele3.append(0)
            ele4.append(0)
        elif eleccion==3:
            ele1.append(0)
            ele2.append(0)
            ele3.append(1)
            ele4.append(0)
        else:
            ele1.append(0)
            ele2.append(0)
            ele3.append(0)
            ele4.append(1)

    dict_data_frames[base]["brand1"]=ele1
    dict_data_frames[base]["brand2"]=ele2
    dict_data_frames[base]["brand3"]=ele3
    dict_data_frames[base]["brand4"]=ele4

# Guardo el diccionario de todas las bases de datos utilizado en un objeto

fin = dict_data_frames
```

Procedemos a incorporar las bases de datos simuladas en la función para evaluar el modelo de logit condicional

In [210]:
```
def modelo_yogurth_MC(x,diccionario,base_de_datos):
    """Logit condicional usando los datos de la base proxy"""
    #Parametros desconocidos
    [alph1,alph2,alph3,bp,bf] = x
    #Normalizar \alpha_{4} = 0
    alph4 = 0
    # Valores vacios
    lden = 0
    # Importar la base de datos
    # diccionario = el diccionario que contiene las 100 bases
    # base_de_datos = base contenia en el diccionario
    dict_data_frames = diccionario
    data = dict_data_frames[base_de_datos]
    # Variables para cada producto
    alphas =[alph1,alph2,alph3,alph4]
    precios = ["price1","price2","price3","price4"]
    Yin = ["brand1","brand2","brand3","brand4"]
    feat = ["feat1","feat2","feat3","feat4"]

    for index, row in data.iterrows():

        #Denominador
        den = 0
        for producto in range(4):
            den += exp(alphas[producto]+ bp*row[precios[producto]] + bf*row[feat[producto]])

        # Logaritmo natual de la suma
        for producto in range(4):
            if den == 0:
                continue
            else:
                #Numerador
                lden += row[Yin[producto]]* log(exp(alphas[producto]+ bp*row[precios[producto]] + bf*row[feat[pr
                moly = -lden
    return moly
```

Ahora, vamos a realizar la optimizacion para las 100 bases de datos mediante la siguiente función

In [211]:
```
def Monte_carlo():
    conca = pd.DataFrame()
    for index, (key, value) in enumerate(dict_data_frames.items()):
        print(index) # Control de tiempo
        result = optimize.minimize(modelo_yogurth_MC, x0=[0,0,0,0,0],args=(fin,key))
        conca = pd.concat([conca,pd.DataFrame(result.x)],axis=1)
    conca = pd.DataFrame.transpose(conca)
    conca.rename({0: 'alph1',1: 'alph2',2: 'alph3',3: 'bp',4: 'bf'}, axis=1, inplace=True)
    conca["alph4"] = 0
    conca.reset_index(drop=True, inplace=True)
    return conca
```

Se guardan los resultados en un archivo csv para la posterior utilización de los datos

In [ ]:
```
MC_save = pd.DataFrame(Monte_carlo())
MC_save.to_csv("D:/Usuario/Desktop/Cuarto Semestre/Elección discreta/Tarea 1/MC_save.csv")
```

Mediana de los estimadores para cada uno de los 5 coeficientes.

In [212]:
```
# Cargamos los datos
base_B = pd.read_csv("D:/Usuario/Desktop/Cuarto Semestre/Elección discreta/Tarea 1/MC_save.csv")
print(pd.DataFrame.median(base_B))
```

```
Unnamed: 0    12.000000
alph1          0.940027
alph2         -0.909311
alph3          0.554207
bp           -19.570920
bf             1.912652
alph4          0.000000
dtype: float64
```

Histograma con la distribución de los estimadores para cada coeficiente.

In [213]:
```
base_B.drop(base_B.columns[0], axis=1, inplace=True)
```

```
In [214]: base_B.hist(layout=(3,2),figsize=(8,8),grid=False,color="#800080",zorder=2, rwidth=0.9)
```

```
Out[214]: array([[<AxesSubplot:title={'center':'alph1'}>,
                  <AxesSubplot:title={'center':'alph2'}>],
                 [<AxesSubplot:title={'center':'alph3'}>,
                  <AxesSubplot:title={'center':'bp'}>],
                 [<AxesSubplot:title={'center':'bf'}>,
                  <AxesSubplot:title={'center':'alph4'}>]], dtype=object)
```

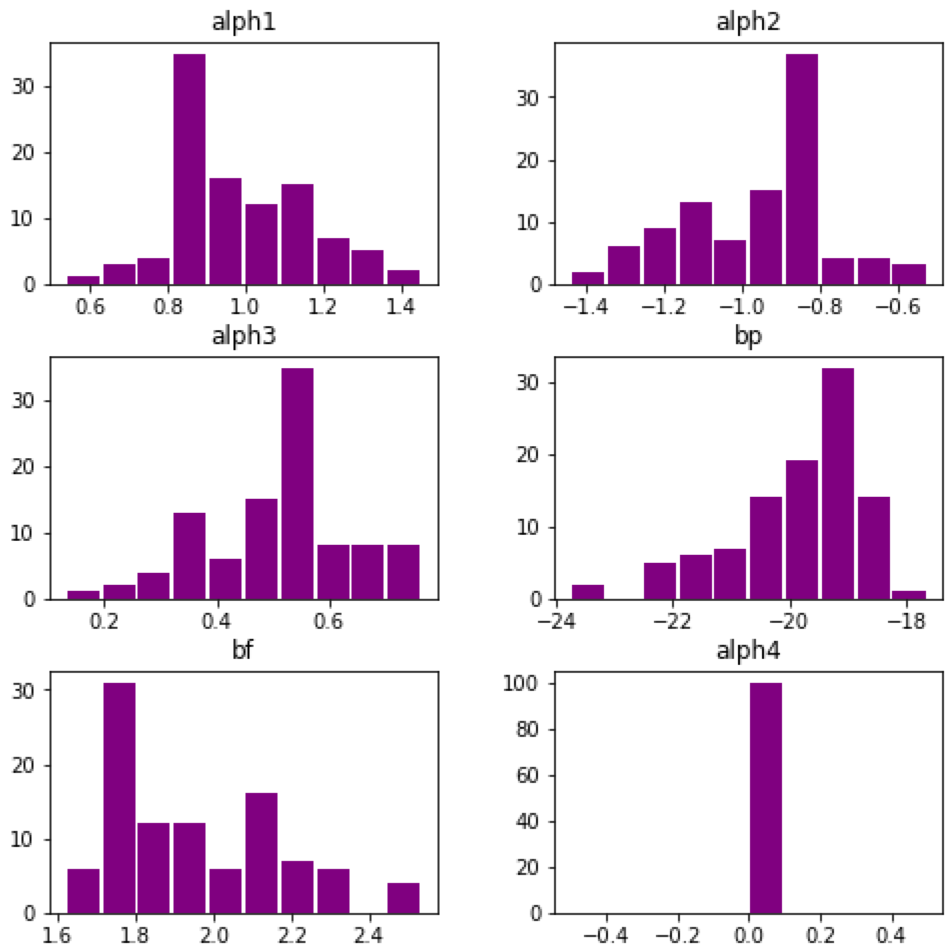

Fin